

AttnRes 的分块拓扑：93 层被切成8 块 / 9 个信息源

AttnRes 把注意力从序列轴搬到深度轴：每层不再只读那一个累加下来的 $\mathbf{h}$ ，而是对此前各层做一次 softmax 检索。K3 又每 12 层切一刀——代码里那行 `prefix_sum = None` 把主干残差流清零，跨块因此没有恒等直连，只剩总线上的凸组合。

Kimi K3 §2.2 / `config.json`: `attn_res_block_size=12, num_hidden_layers=93` / `modeling_kimi_linear.py`:985--1046, 1188--1233

(a) 同一手法，两条轴 —— 把注意力从横着的序列轴转 90° 放到竖着的深度轴上：每列的上下两图是同一张图，只是转了个向

