


$$\mathbf{H}^{(0)} = \mathbf{X}_p \mathbf{W}_e^\top + \text{Interp}_{78 \times 138}^{\text{bil}}(\mathbf{P}), \quad \mathbf{H}^{(\ell)} = \text{Block}_\ell(\mathbf{H}^{(\ell-1)}; \mathcal{R}_{x,y}^{2\text{D}}), \quad \ell = 1, \dots, 27$$

$$\mathbf{V} = \text{RMSNorm}(\mathbf{W}_2 \phi(\mathbf{W}_1 \text{PS}_{2 \times 2}(\mathbf{H}^{(27)}))), \quad \mathbf{E}[\pi(i)] = \text{Emb}(u_i), \quad \pi(i) = \left(\sum_{j \leq i} n_j\right) - 1, \quad \mathbf{E}[\mathcal{M}] = \mathbf{V}$$

$$n_j = 2691 \text{ 当 } u_j = \text{<media_pad>, 否则 } n_j = 1; \mathcal{M} \text{ 就是这个占位符撑开的 2691 个空槽——一个 } token \text{ 位膨胀成一张大图}$$

(a) 原生分辨率预处理 → patchify——不缩放、不裁剪、不切 tile: 只在右侧和下方补零, 把边长补齐到 $28 = 2 \times 14$ 的整数倍




原生分辨率的三道闸门 (navit_resize_image)

$s_1 = \sqrt{65536/(\lfloor W/14 \rfloor \cdot \lfloor H/14 \rfloor)}$: 总 patch 数 ≤ in_patch_limit = 65536。正方形图的上界正好是边长 256 × 14 = 3584 ——就是论文里写的 3584 × 3584。


$s_2, s_3 = 512 \cdot 14/W, 512 \cdot 14/H$: 单边 ≤ 512 个 patch = 7168 px。

$s = \min(1, s_1, s_2, s_3)$ ——只缩小、不放大。本例 137 × 77 = 10549 ≪ 65536, 三条闸门都不触发, 原尺寸直接进入模型。


(b) patch 嵌入 + 可插值的 2D 绝对位置编码——Conv2d(k=14,s=14) 等价于「把每个 patch 拉成 588 维再过一个线性层」; 位置表尺寸固定 64×64, 靠双线性插值适配任意分辨率



(c) MoonViT-V2 编码器 × 27 层——RMSNorm 前置、全线 bias=False; 注意 $d_{\text{qkv}}=1536 \neq d=1024$, 注意力内部比残差流更宽



(d) 2×2 pixel shuffle → MLP projector——token 数除以 4、通道数乘以 4: 信息不丢, 只是换轴; 再由两层 MLP 抬到 LLM 的 d=7168



(e) 文本分支 → 一个占位符膨胀成 2691 个槽——图片在文本里只占 <media_pad> 一个 token; 拼接时按 $\pi = \text{cumsum}(n) - 1$ 重排文本, 剩下的空位灌进视觉特征

