


$$\mathbf{S}_t = (\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) \text{Diag}(\boldsymbol{\alpha}_t) \mathbf{S}_{t-1} + \beta_t \mathbf{k}_t \mathbf{v}_t^\top, \quad \tilde{\mathbf{o}}_t = \mathbf{S}_t^\top \mathbf{q}_t$$


$$\mathbf{g}_t^h = g_{\min} \text{Sigmoid}(e^A \mathbf{z}_t^h), \quad \boldsymbol{\alpha}_t^h = \exp(\mathbf{g}_t^h), \quad \mathbf{y}_t = \mathbf{W}_o [\text{Sigmoid}(\mathbf{W}_g \mathbf{x}_t) \odot \text{RMSNorm}(\tilde{\mathbf{o}}_t)]$$

绿色是 **K3** 相对 Kimi Linear 改动的两处：把对数衰减下界化 ($g_{\min} = -5$)，把输出门从低秩换成满秩 $\mathbf{W}_g$

(a) **q, k, v 三路投影**——和 MLA 一样， $d=7168 \neq h \cdot d_v=12288$ ；扁平的头主序形只出现在投影之后，一次 **rearrange** 就成 4 维



(b) **逐通道遗忘门 α** ——低秩产生衰减 logits，再经有下界的缩放 Sigmoid 压到 $(-5, 0)$ ；这是 K3 相对 Kimi Linear 的关键改动




下界化换来了什么

Kimi Linear: $g = -e^A \text{Softplus}(\mathbf{z}) \in (-\infty, 0)$ ，分块形式里的 $1/\Gamma$ 可无界增长。

K3: $g \in (-5, 0) \Rightarrow 16\text{-token}$ 小块的累计对数衰减 $\in (-80, 0)$, $1/\Gamma < e^{80} \approx 5.5 \times 10^{34}$ ，稳落在 BF16 动态范围内。

于是对角块也能走稠密 *Tensor Core matmul*，去掉了逐位置对的对角路径。

(c) **写入强度 β** ——和 α 同是 (0, 1) 里的门，但粒度差 128 倍： α 逐通道， β 每头只有一个数




α 与 β 的分工

$\alpha_t^h \in (e^{-5}, 1)^{128}$ ：逐通道，进 $\text{Diag}(\alpha_t)$ ，决定旧状态的每个 key 通道各自忘掉多少。

$\beta_t^h \in (0, 1)$ ：每头一个标量——整条 β 一个位置只有 96 个数，在 $(\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top)$ 和 $+\beta_t \mathbf{k}_t \mathbf{v}_t^\top$ 里是同一个数——擦掉多少旧的，就写入多少新的。

因为 $\mathbf{k}_t$ 已 L_2 归一化， $\beta_t=1$ 时 $\mathbf{I} - \mathbf{k}_t \mathbf{k}_t^\top$ 恰是把 $\mathbf{k}_t$ 方向投影掉的正交投影，即完全替换该方向的记忆； $\beta_t \rightarrow 0$ 则这一步几乎不动状态。

(d) **递推：一步状态转移**——以下换成单头 h 、单步 t 视角；先逐通道衰减，再按 delta 规则删旧写新。 $d_k=d_v=128$ 故 $\mathbf{S}$ 是方阵




KDA 一层的推理状态

$\mathbf{S}$: ($B, 96, 128, 128$) = 1,572,864 元素/序列，与 T 无关；另有 q, k, v 三份宽度 4 的卷积滑窗。

对比一层 Gated MLA 的 576/token：要到 $T \approx 2731$ 才追平一层 KDA 的常数状态。

93 层里 69 层 KDA，24 层 MLA (3:1)。

(e) **输出**——先做逐头 RMSNorm (在 $d_v=128$ 上归一)，再乘满秩门，最后展平过 $\mathbf{W}_o$ 。与 MLA 的差别就是多了这个 RMSNorm



轴 B 批 (全图省略不画)； T 序列位置 ((a)(b)(c)(e) 的面高，(d) 里已消去)； $h=96$ 头 (叠片深度)； $d=7168$ 模型宽度 $\neq h \cdot d_v=12288$ ； $d_k=d_v=128$ ，故 $\mathbf{S} \in \mathbb{R}^{128 \times 128}$ 是方阵；衰减低秩瓶颈也恰好是 128。

对象 q, k : L_2 归一化后的单位向量； v : 值向量 (不做 $L_2 \text{Norm}$)。 $\alpha_t \in (e^{-5}, 1)^{d_k}$: 逐通道保留因子，越接近 1 记得越久。 $\beta_t \in (0, 1)$: 每头一个标量，整层 β 是 ($B, T, 96$)，delta 写入强度。 $\mathbf{S}$: 值的累加器，不是概率也不是注意力矩阵。 $\mathbf{g}_{\text{out}} \in (0, 1)^{12288}$: 逐通道输出门 (图中 σ 即 Sigmoid)。 A : $\mathbf{A}_{\log}$ 在 checkpoint 里是 [128] (= d_k)，论文与参考实现写的却是逐头标量 [96]——两者对不上。

机制 (i) 一步递推分三件事： $\text{Diag}(\alpha_t)$ 做逐通道衰减 (对 $\mathbf{S}$ 逐行缩放)； $(\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top)$ 是秩 1 投影，按 delta 规则擦掉旧的 $\mathbf{k}_t$ 分量； $+\beta_t \mathbf{k}_t \mathbf{v}_t^\top$ 是秩 1 写入。 读出 $\tilde{\mathbf{o}}_t = \mathbf{S}_t^\top \mathbf{q}_t$ 用的是更新后的状态。 (ii) 训练与 prefill 实走分块并行形式： $\mathbf{A}_{[t]} = \text{Tril}[(\mathbf{Q}_{[t]} \odot \boldsymbol{\Gamma})(\mathbf{K}_{[t]}/\boldsymbol{\Gamma})^\top]$ ， $\mathbf{O}_{[t]} = (\boldsymbol{\Gamma} \odot \mathbf{Q}_{[t]})\mathbf{S}_{[t]} + \mathbf{A}_{[t]}\tilde{\mathbf{V}}_{[t]}$ ； Tril 含对角，正因为读的是更新后的状态。 (iii) 张量布局：KDA 全程 token 主序 **b t h d**，与 MLA 的 **b h t d** 正相反；格数只表示轴的结构与拼合关系，不是真实维度 (d 已压缩)。权重的 $\times$ 形状一律按 (输出 $\times$ 输入) 写，与公式里的 $\mathbf{W}\mathbf{x}$ 及 checkpoint 的 `.weight.shape` 一致； $\rightarrow$ 只表示维度流向。